Laboratorio 8 - Visión Por Computadora

Autores:

- Nelson García
- Joaquín Puente
- Diego Linares

Link al repositorio: https://github.com/Its-Japo/VisionXComputadora/tree/main/Lab_8

Task 1

El siguiente conjunto de preguntas evalúa su capacidad de analizar, justificar y conectar los fundamentos matemáticos de la detección de objetos con decisiones de ingeniería reales dentro del proyecto VisorShelf. No basta con enunciar fórmulas: se espera que usted explique el significado de cada término y argumente su relevancia práctica en el contexto de auditoría de anaqueles.

Pregunta 1.1

El gerente de producto de VisorShelf le presenta la siguiente situación: el sistema detecta una lata de atún en el anaquel y devuelve la caja predicha $\hat{b}$= (142, 89, 218, 165) en formato (x_min, y_min, x_max, y_max). El radiólogo de calidad del cliente anota manualmente la caja real b* = (138, 84, 222, 170). El cliente pregunta: "¿Qué tan buena es esa detección?"

1) Cálculo manual del IoU

Se tiene:

Caja predicha:

b^ = (142,89,218,165)

Caja real (ground truth):

b^* = (138,84,222,170)

Formato: $(x_{min}, y_{min}, x_{max}, y_{max})$

Paso 1: área de la caja predicha

Ancho: 218 − 142 = 76

Alto: 165 − 89 = 76

Área: |b^| = 76 * 76 = 5776

Paso 2: área de la caja real

Ancho: 222 − 138 =84

Alto: 170 − 84 = 86

Área: Ib*I = 84 * 86 = 7224

Paso 3: calcular la intersección

Para la intersección:

x^I_{min} = max(142,138) = 142

y^I_{min} = max(89,84) = 89

x^I_{max} = min(218,222) = 218

y^I_{max} = min(165,170) = 165

Entonces:

Ancho intersección: 218 − 142 = 76

Alto intersección: 165 − 89 = 76

Área de intersección: III = 76 * 76 = 5776

Paso 4: calcular la unión

Por inclusión-exclusión:

IUI= Ib^I + Ib*I − III

Sustituyendo: IUI = 5776 + 7224 − 5776 = 7224

Paso 5: calcular IoU

IoU = IUI/III = 7224/5776 ≈ 0.799

IoU ≈ 0.80

Un IoU de 0.80 significa que la caja que predijo el sistema se superpone muy bien con la ubicación real del producto. En palabras simples: el sistema sí encontró la lata de atún y la marcó bastante cerca de donde realmente está. No es perfecta, pero para una tarea de auditoría de anaqueles es una detección buena y confiable. La definición formal de IoU y su cálculo por intersección/unión aparece en el material de detección del curso.

2)

En la fórmula:

IoU = IUI / IIIIII: área de intersección, es decir, la parte que comparten la caja predicha y la caja real.

|U|: área de unión, es decir, toda la región cubierta por cualquiera de las dos cajas.

¿Por qué usar la unión y no solo el área del ground truth?

Porque la unión penaliza tanto quedarse corto como pasarse:

- Si la predicción es muy pequeña, la intersección baja.
- Si la predicción es demasiado grande, la unión crece mucho.
- Si la caja está desplazada, la intersección cae y la unión sigue siendo grande.

Si el denominador fuera solo el área del ground truth, una caja muy grande que cubra el objeto y bastante fondo podría parecer artificialmente "buena". Usar la unión evita premiar predicciones infladas o descuidadas. Ese diseño hace la métrica más justa y más robusta frente a detectores que "abrazan" demasiado contexto del anaquel.

Evita que el modelo gane puntuación simplemente dibujando cajas excesivamente grandes para asegurarse de tocar el producto. En VisorShelf eso sería grave, porque una caja demasiado amplia podría invadir productos vecinos y distorsionar decisiones de inventario, planograma o conteo frontal.

3)

En un anaquel, la meta de negocio no es competir por localización "milimétrica", sino detectar correctamente presencia, ausencia y ubicación razonable del producto. Un umbral de 0.5 suele aceptar detecciones útiles aunque la caja no sea perfecta; 0.75 es más estricto y exigiría una alineación muy fina. El material del curso justamente presenta 0.5 como umbral histórico y 0.75 como criterio más exigente.

Impacto operativo

Con $\theta=0.75$:

- aumentan los falsos negativos.
- una detección útil podría rechazarse por no ajustar con suficiente precisión.
- el sistema podría reportar quiebres de stock inexistentes o dejar productos "sin detectar".

Con $\theta=0.5$:

- se tolera una localización menos fina;
- baja el riesgo de perder productos presentes;
- es más adecuado cuando lo importante es auditoría de anaquel y no recorte exacto para robótica o inspección de alta precisión.

Recomendación práctica:

Producción: usar IoU = 0.5 como criterio de validez. Evaluación interna adicional: también monitorear IoU más altos (por ejemplo 0.75) para medir calidad fina del posicionamiento.

En retail, un falso negativo puede ser costoso porque el sistema puede "ver vacío" donde sí hay producto, generando acciones innecesarias. Un falso positivo también molesta,

pero normalmente es más manejable que perder visibilidad real sobre stock. Por eso 0.5 es mejor balance para este caso.

Pregunta 1.2

Durante una prueba piloto en una tienda de conveniencia, el detector de VisorShelf analiza una imagen con 15 productos en el anaquel. El modelo genera 18 predicciones. Tras aplicar el umbral IoU = 0.5, el equipo clasifica: 12 TP, 6 FP y 3 FN:

Se reporta:

TP = 12 FP = 6 FN = 3

4)

Precisión P = TP / (TP + FP) = 12 / 12 + 6 = 12 / 18 = 0.667 P = 0.67 o 66.7%

Recall R = TP / TP + FN = 12 / 12 + 3 = 12 / 15 = 0.8 R=0.80 o 80%

Explicación de cada denominador

En Precisión: TP + FP

representa todas las detecciones que el sistema afirmó como positivas. Es decir: todo lo que el sistema dijo “aquí hay un producto”.

TP: aciertos. FP: falsas alarmas.

Entonces la Precisión responde: de todo lo que el sistema marcó, cuánto era correcto.

En Recall: TP + FN

representa todos los objetos reales que realmente estaban en la imagen.

TP: objetos reales detectados. FN: objetos reales que el sistema no encontró.

Entonces el Recall responde: de todos los productos que sí existían, cuántos logró recuperar el sistema.

¿Por qué ambas métricas son necesarias?

Porque miden fallas distintas:

Precisión alta evita llenar el sistema de falsas alarmas. Recall alto evita perder productos reales.

Un detector puede tener Recall alto detectando casi todo, pero generando muchas cajas erróneas. O puede tener Precisión alta siendo muy conservador, pero perdiendo muchos productos. En VisorShelf se necesitan ambas perspectivas para entender si el sistema sirve operativamente.

5)

La frase:

“Prefiero que el sistema no se pierda ningún quiebre de stock, aunque a veces nos avise falsas alarmas.”

se traduce a:

- priorizar Recall alto
- aceptar una Precisión más baja si es necesario

Ajustaría el umbral de confianza τ hacia abajo.

Porque al bajar τ: se aceptan más detecciones; suben los TP potenciales; baja el número de FN; mejora el Recall. El costo es que también pueden subir los FP, y por tanto bajar la Precisión.

Para operaciones, perder un quiebre real de stock puede implicar: venta perdida, reposición tardía, anaquel vacío sin atención.

En cambio, una falsa alarma genera revisión innecesaria, pero suele ser menos costosa que no detectar una ausencia real. Por eso la preferencia del director es claramente una preferencia por Recall.

6)

El mAP (Mean Average Precision) es la métrica estándar para evaluar detectores de objetos.

- 1. para cada clase se construye la curva Precisión–Recall variando el umbral de confianza τ;
- 2. se calcula el AP (Average Precision) como el área bajo esa curva;
- 3. luego se promedian los AP de todas las clases para obtener el mAP.

¿Por qué es más informativo?

Porque un único valor de Precisión o Recall depende de un solo punto operativo, es decir, de un solo umbral de confianza. En cambio, el mAP resume el comportamiento del detector a lo largo de muchos umbrales, mostrando mejor el trade-off real entre detectar más y equivocarse más.

Eso es importante en VisorShelf porque el sistema podría operar distinto según la política del cliente:

- una tienda puede preferir Recall alto.
- otra puede querer menos falsas alarmas.
- mAP permite comparar modelos de forma más completa.

mAP@0.5 (PASCAL VOC)

Usa un solo criterio de acierto:

IoU $\geq$ 0.5

Si la caja supera ese umbral, cuenta como detección correcta. Es una evaluación más permisiva respecto a la localización.

mAP@0.5:0.95 (COCO)

Promedia el AP sobre múltiples umbrales IoU:

0.50,0.55,0.60,…,0.95

Eso exige que el detector no solo encuentre el objeto, sino que además lo localice bien de forma consistente. El curso señala justamente esa diferencia entre VOC y COCO.

¿Cuál sería más exigente para VisorShelf?

El más exigente sería:

mAP@0.5:0.95porque castiga cajas imprecisas incluso cuando el objeto fue detectado "más o menos bien". En anaqueles densos, donde productos vecinos son muy parecidos y están muy juntos, esa exigencia extra es relevante: una caja mal ajustada puede invadir el producto contiguo y afectar conteo, ubicación y análisis de planograma.

Pregunta 1.3

En una imagen de anaquel con 40 productos, el modelo de VisorShelf genera 312 cajas candidatas antes de cualquier postprocesamiento. El cliente observa el resultado intermedio y exclama: "¡El sistema está viendo el mismo producto decenas de veces!"

7)

El cliente dice: "¡El sistema está viendo el mismo producto decenas de veces!"

Eso ocurre porque, antes del filtrado final, el detector suele proponer muchas cajas parecidas alrededor del mismo objeto. Esto es normal en detectores modernos, especialmente de una etapa, donde muchas celdas o anclas compiten por explicar la misma región.

El Non-Maximum Suppression (NMS) es el mecanismo que limpia ese resultado.

NMS significa, en esencia: "De varias cajas que parecen apuntar al mismo producto, me quedo con la mejor y elimino las repetidas."

Paso a paso:

- 1. El sistema mira todas las cajas candidatas y sus puntajes de confianza.
- 2. Ordena las cajas desde la más confiable hasta la menos confiable.
- 3. Toma la mejor caja y la conserva.
- 4. Revisa las demás:
- ▪ si una caja se superpone mucho con la ya elegida, asume que probablemente es el mismo producto; entonces la elimina.
- ▪ Repite el proceso con la siguiente caja sobreviviente.

- 5. Al final queda una sola caja por producto, o unas pocas bien separadas.

¿Por qué el detector genera múltiples cajas?

Porque durante la inferencia:

- varias anclas o posiciones distintas pueden responder al mismo producto.
- el modelo no “sabe” desde el inicio cuál de esas cajas es la definitiva.
- por eso propone varias hipótesis cercanas, y luego NMS hace la depuración final. El material del curso describe precisamente este problema de múltiples detecciones y el papel del NMS como refinamiento posterior.

8)

Si el umbral NMS es bajo, el algoritmo se vuelve muy agresivo:

- ve dos cajas cercanas.
- detecta superposición moderada.
- y puede borrar una aunque en realidad correspondan a dos productos distintos uno al lado del otro.

Eso sería peligroso en anaqueles densos, porque podría reducir detecciones válidas y generar falsos negativos.

Riesgo de umbral bajo

- suprime cajas de productos vecinos reales.
- sube FN.
- el sistema puede “fusionar” dos productos contiguos en uno solo.

Riesgo de umbral alto

- deja pasar más duplicados.
- sube FP por detecciones repetidas del mismo objeto.

Para VisorShelf, en estantes apretados, conviene un NMS menos agresivo, o sea con umbral más alto, para no borrar productos verdaderos contiguos. Luego se puede controlar el exceso de duplicados combinándolo con un buen umbral de confianza y calibración del detector.

9)

El orden correcto es:

1. Aplicar primero el umbral de confianza τ
2. Después aplicar NMS

El umbral de confianza elimina primero las cajas evidentemente débiles o improbables. Así, NMS trabaja sobre un conjunto mucho más pequeño y más limpio.

Eso tiene dos ventajas:

- computacional: menos cajas para comparar entre sí.
- estadística: menos ruido compitiendo con cajas buenas.

¿Qué pasaría si se invierte el orden?

Si se corre NMS antes de filtrar por confianza:

NMS tendría que procesar muchísimas cajas irrelevantes; aumentaría el costo computacional; algunas cajas de baja confianza podrían interferir innecesariamente en la supresión.

En el caso descrito:

- 312 cajas candidatas por imagen
- 30 imágenes por minuto
- Eso significa: 312 × 30 = 9360, cajas candidatas por minuto antes de postprocesamiento.

Como NMS compara superposición entre muchas cajas, hacerlo antes de filtrar por confianza encarece bastante el sistema. En un escenario on-premise con CPU media y presupuesto menor a 500 ms por imagen, ese orden sería mala decisión de ingeniería. El flujo típico de detección presentado en clase también ubica primero el filtrado por score y luego la supresión de redundancias.

Task 2

Las siguientes preguntas evalúan su comprensión estratégica de la evolución de los detectores de dos etapas y su capacidad de tomar decisiones de arquitectura justificadas dentro del contexto operativo de VisorShelf. Se valorará la coherencia del argumento con las restricciones reales del sistema.

Pregunta 2.1

El CTO de VisorShelf propone usar el detector original R-CNN (2014) para la primera versión del sistema. El equipo de ingeniería calcula que con el dataset actual y una CPU de tienda, cada imagen tardaría aproximadamente 45 segundos en procesarse. Con esto responda en su reporte:

1)

El cuello de botella principal de R-CNN está en que extrae cada una de las ~2,000 propuestas de región como un recorte independiente de la imagen y ejecuta un pase completo hacia adelante por la CNN para cada uno de ellos de forma separada.

Internamente, la red convolucional ejecuta múltiples capas que realizan millones de operaciones de multiplicación-acumulación sobre los píxeles del recorte. Cuando ese proceso se repite 2,000 veces por imagen, el costo se multiplica directamente: si una

pasada tarda X ms, el total es aproximadamente 2,000 × X ms, sin ningún ahorro por compartir trabajo entre regiones con solapamiento espacial.

El problema central es la ausencia de reutilización de cómputo. Dos propuestas que comparten el 80% de su área realizan dos pasadas completamente independientes, recalculando activaciones intermedias desde cero para píxeles que ya habían sido procesados. En una CPU de tienda sin vectorización avanzada ni GPU, ese costo acumulado explica perfectamente los 45 segundos por imagen.

2)

Feature map compartido

Fast R-CNN invierte el orden del pipeline: en vez de recortar primero y luego procesar, pasa la imagen completa una sola vez por la CNN y obtiene un único feature map. Todas las propuestas de región se proyectan sobre ese feature map ya computado. Esto elimina 1,999 de los 2,000 pases por los bloques convolucionales profundos, que era exactamente el origen del cuello de botella. El cómputo que desaparece es todo el trabajo de las capas convolucionales para cada región redundante.

RoI Pooling

El problema que resuelve es el siguiente: las propuestas de región, al proyectarse sobre el feature map, tienen tamaños distintos. Una región grande cubre más celdas del feature map que una pequeña, y las capas fully connected que siguen necesitan un tensor de tamaño fijo como entrada.

RoI Pooling resuelve esto dividiendo cada región proyectada en una grilla H×W fija (típicamente 7×7) sin importar su tamaño real, y aplicando max-pooling dentro de cada celda. La operación es: para cada una de las H×W celdas, se toma el valor máximo de los elementos del feature map que caen dentro de esa celda. El resultado es siempre un tensor H×W×C, independientemente de si la región original tenía 3 o 30 celdas en el feature map.

3)

Con Fast R-CNN el tiempo de la CNN bajó de ~40 s a ~0.3 s/imagen, pero el total seguía siendo ~2.3 s. El nuevo cuello de botella era **Selective Search**, el algoritmo que genera las ~2,000 propuestas de región y que consumía los ~2 segundos restantes.

El problema con Selective Search no es simplemente que sea lento. El problema arquitectónico más profundo es que es un algoritmo externo, no aprendido, que opera sobre píxeles crudos usando heurísticas de agrupamiento de bajo nivel como color, textura y tamaño. Eso implica tres limitaciones fundamentales:

1. **No aprende con los datos.** No puede entrenarse con backpropagation. Sin importar cuántas imágenes de anaqueles se tengan, Selective Search siempre generará propuestas de la misma forma, ignorando el dominio.
2. **No comparte el entendimiento semántico del backbone.** La CNN ya ha aprendido qué regiones son interesantes; Selective Search trabaja completamente

desacoplado de ese conocimiento y genera propuestas sin ninguna noción de lo que el detector considera relevante.

3. **No puede optimizarse de extremo a extremo.** Al estar fuera del grafo computacional, no existe forma de ajustar la calidad de las propuestas en función de la calidad del detector. Son dos sistemas que corren en serie sin retroalimentación entre ellos.

En el contexto de VisorShelf, esto es especialmente problemático: los productos en anaquel tienen formas muy similares entre sí, y Selective Search no tiene mecanismo para aprender a enfocar sus propuestas en las regiones que el dominio de retail requiere.

Pregunta 2.2

El equipo de VisorShelf decide usar Faster R-CNN como base del sistema. Un ingeniero junior pregunta: "*¿Por qué necesitamos una Region Proposal Network si ya tenemos el feature map? ¿No podríamos simplemente hacer sliding window directamente sobre el feature map?*"

4)

La pregunta tiene algo de razón en el punto de partida: sí, hacer sliding window sobre el feature map ya sería más eficiente que Selective Search sobre píxeles crudos. Pero hay una diferencia fundamental entre hacerlo "a ciegas" y lo que hace la RPN.

Un sliding window clásico sobre el feature map revisaría cada posición con ventanas de tamaño fijo, devolviendo regiones candidatas distribuidas uniformemente sin ningún criterio aprendido sobre si esa posición probablemente contiene un objeto. Sería como revisar sistemáticamente cada celda de la grilla sin tener conocimiento previo del contenido.

La RPN, en cambio, usa una pequeña red convolucional (típicamente 3×3) que desliza sobre el feature map y en cada posición predice: (a) si hay un objeto ahí o no, y (b) cómo ajustar los anchors predefinidos para que encajen mejor con ese objeto. La RPN aprende a reconocer las características semánticas de las regiones que contienen objetos.

La ventaja semántica es el punto clave: cuando la RPN "mira" una posición en el feature map, no está viendo píxeles crudos sino representaciones comprimidas que ya codifican texturas, bordes, formas y relaciones espaciales aprendidas de millones de imágenes. Una celda del feature map que corresponde a una botella en el anaquel ya tiene activaciones muy distintas a una celda de fondo vacío. El sliding window clásico no puede hacer esa distinción porque opera antes de cualquier comprensión semántica, o sobre píxeles en los que esa comprensión aún no existe.

5)

Los anchors son cajas de referencia predefinidas que se colocan en cada posición del feature map. Funcionan como hipótesis iniciales sobre dónde y de qué tamaño podría ser

un objeto detectado. En Faster R-CNN se usan 9 anchors por posición: 3 escalas × 3 relaciones de aspecto (cuadrado, horizontal, vertical), cubriendo así una amplia variedad de formas y tamaños sin que la red tenga que "inventar" cajas desde cero.

La red predice **deltas** (Δx, Δy, Δw, Δh) en lugar de coordenadas absolutas por tres razones prácticas:

- Los deltas son números pequeños centrados alrededor de cero, lo que estabiliza el entrenamiento y evita que el gradiente tenga que mover los pesos en rangos arbitrariamente grandes.
- Si el anchor ya está cerca del objeto real, el delta necesario es pequeño, y la red tiene una tarea de regresión mucho más sencilla.
- Los deltas son relativos al anchor, lo que hace al modelo más generalizable a distintas resoluciones y posiciones en la imagen.

En la decodificación **w = w_a · e^(Δw)**:

- **w**: ancho final de la caja predicha
- **w_a**: ancho del anchor de referencia (conocido, predefinido)
- **Δw**: el delta de escala logarítmica predicho por la red
- **e^(Δw)**: la exponencial garantiza que el resultado siempre sea positivo, ya que un ancho negativo carece de sentido físico. Además, trabaja en escala logarítmica: Δw = 0 → sin cambio (e^0 = 1), Δw > 0 → caja más ancha, Δw < 0 → caja más estrecha. Esta escala hace que los ajustes sean proporcionales al tamaño del anchor, lo que es más robusto para detectar objetos de muy distintos tamaños.

6)

Faster R-CNN con VGG16 logra ~5 FPS en GPU, equivalente a ~200 ms por imagen. La restricción de VisorShelf es <500 ms. En GPU cumpliría, pero el sistema opera **on-premise sin GPU dedicada**, y en CPU el mismo modelo cae a aproximadamente 0.5–1.5 FPS (entre 650 ms y 2 s por imagen), lo que viola directamente la restricción.

Más allá de la velocidad, hay dos factores adicionales relevantes:

Precisión en objetos pequeños y densos: Faster R-CNN con ResNet-50 FPN maneja bien los objetos pequeños gracias a la Feature Pyramid Network, que combina feature maps de distintas escalas. En un anaquel denso con productos de tamaño similar y poco espacio entre ellos, esa capacidad multi-escala es valiosa. Sin FPN, detectar productos pequeños o parcialmente ocluidos se vuelve mucho menos confiable, lo que impactaría directamente la calidad de las auditorías de stock.

Ecosistema de implementación y fine-tuning: Faster R-CNN tiene una integración madura en torchvision, con pesos preentrenados en COCO, documentación extensa y pipelines de fine-tuning bien probados. Para un equipo que necesita adaptar el modelo a nuevas categorías o nuevas tiendas rápidamente, ese ecosistema reduce el tiempo de desarrollo y el riesgo técnico. Los errores y limitaciones conocidos de la arquitectura también facilitan el diagnóstico en producción.

Recomendación: Para el hardware actual (CPU sin GPU), Faster R-CNN con VGG16 no es recomendable para producción tal como está. Con la variante ResNet-50 FPN optimizada o con técnicas como quantización o exportación a ONNX podría reconsiderarse. Para el escenario actual, una arquitectura de una sola etapa más ligera es la opción más práctica.

Pregunta 2.3

El equipo de producto presenta dos propuestas para el detector de producción de VisorShelf: **Propuesta A: Faster R-CNN + ResNet50 + FPN** vs **Propuesta B: YOLOv8n (nano) finetuned**

7)

Para el escenario actual de VisorShelf, **recomendamos la Propuesta B: YOLOv8n**, y la razón va más allá de los números de velocidad.

Con CPU de gama media y sin GPU, Faster R-CNN a ~1.5 FPS tarda aproximadamente 667 ms por imagen, lo que viola directamente la restricción operativa de <500 ms. YOLOv8n a ~15 FPS tarda ~67 ms, con un margen de 7× sobre el requerimiento. No es solo "más rápido": es la diferencia entre un sistema que cumple su SLA operativo y uno que no puede operar en producción.

Más allá del número de FPS, hay razones arquitectónicas que refuerzan esta decisión:

Arquitectura de una sola etapa: YOLOv8n no tiene la sobrecarga del pipeline de dos etapas (RPN + clasificador). En hardware limitado, cada operación extra cuenta, y la ausencia de la RPN elimina un componente completo del grafo computacional.

Tamaño del modelo crítico en hardware de tienda: 6 MB vs 160 MB no es solo almacenamiento. Un modelo de 6 MB carga en RAM en milisegundos, tiene mejor localidad de caché en CPU y facilita actualizaciones remotas en una red de tiendas. Operativamente, esto importa cuando se necesita hacer rollbacks o deployments frecuentes.

Costo de fine-tuning bajo: Los productos en anaquel cambian constantemente (nuevos SKUs, cambios de empaque, temporadas). Un sistema que requiere menos esfuerzo para reentrenarse tiene menor costo operativo a largo plazo, lo que es estratégicamente relevante para una startup como VisorShelf.

La diferencia de mAP@0.5 (37 vs 55 en COCO) es real pero debe contextualizarse: esos benchmarks son en COCO con 80 clases heterogéneas. En un dominio específico como retail con fine-tuning adecuado sobre datos del dominio, la brecha entre arquitecturas tiende a reducirse. Un sistema funcional en tiempo real con mAP razonable entrega más valor operativo que uno más preciso que no cumple la latencia.

8)

Sí, con una RTX 3060 **cambiaríamos la recomendación a Faster R-CNN + ResNet50 + FPN**.

La razón es que la GPU elimina el único obstáculo real que tenía Faster R-CNN: a 8–12 FPS (83–125 ms por imagen) cumple el requerimiento de <500 ms con un margen de 4–6×. En ese escenario, la velocidad deja de ser el criterio diferenciador.

Con la restricción de latencia resuelta, el trade-off se inclina claramente hacia la calidad de detección:

- **18 puntos de mAP@0.5 de ventaja (55 vs 37):** En auditoría de anaqueles, esa diferencia se traduce directamente en menos quiebres de stock no detectados y menos falsas alarmas.
- **FPN multi-escala:** En anaqueles densos, la capacidad de detectar objetos pequeños y parcialmente ocluidos a múltiples escalas es una ventaja real. Los productos en retail frecuentemente se superponen, están a distintas distancias de la cámara y aparecen parcialmente bloqueados.
- **Contexto de tienda flagship:** Una tienda flagship justifica el costo de la GPU y puede aprovechar la mayor precisión para análisis más sofisticados como cumplimiento de planograma, análisis de facings o detección de productos fuera de lugar.

En este escenario, YOLOv8n quedaría como opción para tiendas con hardware más limitado, mientras Faster R-CNN se convertiría en el modelo de referencia para las flagship.

9)

El riesgo técnico específico es el **catastrophic forgetting** (olvido catastrófico), también conocido en el contexto de transfer learning como **feature degradation** o destrucción del preentrenamiento.

El problema ocurre de la siguiente forma: el backbone de Faster R-CNN tiene pesos preentrenados en COCO sobre millones de imágenes, representando características generales y transferibles como bordes, texturas, formas y gradientes. Si se aplica el mismo learning rate alto a todo el modelo, el gradiente proveniente del dataset de anaqueles (pequeño y específico) actualiza esos pesos con pasos grandes, sobreescribiendo representaciones aprendidas que eran valiosas. El backbone pierde capacidad de generalizar y olvida lo que sabía antes de ver los datos de retail.

El síntoma típico es convergencia rápida en entrenamiento pero mala generalización en validación, o pesos del backbone que divergen hacia valores que ya no representan ninguna característica visual útil.

Mitigación mediante learning rate diferenciado:

La solución estándar es usar learning rates distintos para distintas partes del modelo:

- **Backbone congelado inicialmente (épocas 1–N):** LR del backbone = 0. Solo se entrena el cabezal. Esto permite que el cabezal aprenda a usar las features existentes

sin perturbar el backbone.

- **Descongelamiento gradual:** Se descongela el backbone con un LR muy pequeño (e.g., 1e-5), mientras el cabezal sigue con LR mayor (e.g., 1e-3 a 1e-4). El backbone se adapta lentamente al dominio de retail sin olvidar lo aprendido en COCO.

Esta técnica es especialmente importante cuando el dataset de fine-tuning es pequeño, como en este experimento, porque hay menos gradiente disponible para justificar cambios grandes en el backbone. Con pocos datos, un LR uniforme alto es una receta directa para el catastrophic forgetting.

Task 3

Entrenamiento y evaluación comparativa de dos detectores de objetos pre-entrenados (Faster R-CNN y SSD300) para detectar productos en imágenes de anaquel, en el contexto del sistema **VisorShelf**.

#	Arquitectura	Backbone	Pre-entrenamiento	Justificación
1	**Faster R-CNN**	ResNet-50 FPN	COCO	Detector de dos etapas; alta precisión; referencia clásica
2	**SSD300**	VGG-16	COCO	Detector de una etapa; mayor velocidad; candidato on-premise

Dataset: COCO 2017 filtrado por categorías de productos relevantes para anaquel (`bottle`, `cup`, `bowl`, `wine glass`), descargado directamente desde los servidores oficiales. SKU-110K fue considerado pero no dispone de descarga programática pública. Open Images V7 fue descartado por requerir MongoDB.

0. Entorno

In [22]:
```
# Instalar dependencias
!pip install -q torchmetrics pycocotools tqdm
```

In [23]:
```
import os, json, time, copy, random, collections, urllib.request, zipfile
from pathlib import Path

import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as patches
from PIL import Image
from tqdm.auto import tqdm

import torch
import torchvision
import torchvision.transforms as T
from torch.utils.data import Dataset, DataLoader

from torchvision.models.detection import (
    fasterrcnn_resnet50_fpn, FasterRCNN_ResNet50_FPN_Weights,
```

```
)
from torchvision.models.detection.faster_rcnn import FastRCNNPredictor
from torchvision.models.detection import ssd300_vgg16, SSD300_VGG16_Weights
from torchvision.models.detection.ssd import SSDClassificationHead
from torchvision.models.detection._utils import retrieve_out_channels

from pycocotools.coco import COCO
from torchmetrics.detection.mean_ap import MeanAveragePrecision

SEED = 42
random.seed(SEED)
np.random.seed(SEED)
torch.manual_seed(SEED)

DEVICE = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
print(f'Dispositivo: {DEVICE}')
if DEVICE.type == 'cuda':
    print(f'GPU: {torch.cuda.get_device_name(0)}')
```

```
Dispositivo: cuda
GPU: NVIDIA GeForce RTX 4060 Laptop GPU
```

1. Preparación del Dataset

1a. Descarga — COCO 2017 filtrado por categorías de anaquel

Se descarga el dataset **COCO 2017** y se filtra por categorías de productos relevantes para un anaquel de tienda de conveniencia:

- `bottle` — bebidas y productos envasados
- `cup` — vasos y tazas
- `bowl` — recipientes
- `wine glass` — copas y cristalería

Fuente: COCO 2017 (Creative Commons Attribution 4.0).
Proceso: Se descargan primero los archivos de anotaciones (~241 MB), se identifican las imágenes que contienen las categorías objetivo, y se descargan solo esas imágenes directamente desde los servidores de COCO — sin necesidad de MongoDB ni servicios externos.

> **Nota:** Se intentó usar SKU-110K (dataset diseñado específicamente para anaqueles densos, CVPR 2019) pero no dispone de descarga programática pública. Open Images V7 fue descartado porque requiere MongoDB a través de FiftyOne. COCO 2017 cubre el mismo dominio con descarga totalmente reproducible.

In [24]:
```
TARGET_CATS = ['bottle', 'cup', 'bowl', 'wine glass']
DATA_ROOT = Path('./shelf_data')
DATA_ROOT.mkdir(exist_ok=True)

# 1. Descargar anotaciones COCO 2017 (~241 MB, una sola vez)
ann_zip = DATA_ROOT / 'annotations_trainval2017.zip'
```

```python
ann_dir = DATA_ROOT / 'annotations'
if not ann_dir.exists():
    print('Descargando anotaciones COCO 2017 (~241 MB)...')
    urllib.request.urlretrieve(
        'http://images.cocodataset.org/annotations/annotations_trainval2017.zip'
        ann_zip
    )
    print('Extrayendo...')
    with zipfile.ZipFile(ann_zip) as z:
        z.extractall(DATA_ROOT)
    ann_zip.unlink()  # liberar espacio
print('Anotaciones listas.')

# 2. Cargar APIs de COCO y muestrear imágenes con categorías objetivo
coco_train_api = COCO(str(ann_dir / 'instances_train2017.json'))
coco_val_api   = COCO(str(ann_dir / 'instances_val2017.json'))

def sample_img_ids(coco_api, n):
    cat_ids = coco_api.getCatIds(catNms=TARGET_CATS)
    img_ids = set()
    for cid in cat_ids:
        img_ids.update(coco_api.getImgIds(catIds=[cid]))
    ids = sorted(img_ids)
    random.seed(SEED)
    random.shuffle(ids)
    return ids[:n]

train_ids = sample_img_ids(coco_train_api, 500)
all_val   = sample_img_ids(coco_val_api,   200)
val_ids, test_ids = all_val[:100], all_val[100:]
print(f'Imágenes seleccionadas — train: {len(train_ids)}, val: {len(val_ids)}, t

# 3. Descargar solo las imágenes necesarias
def download_images(coco_api, img_ids, out_dir):
    out_dir = Path(out_dir)
    out_dir.mkdir(parents=True, exist_ok=True)
    for info in tqdm(coco_api.loadImgs(img_ids), desc=str(out_dir.parent.name)):
        dest = out_dir / info['file_name']
        if not dest.exists():
            urllib.request.urlretrieve(info['coco_url'], dest)

download_images(coco_train_api, train_ids, DATA_ROOT / 'train/data')
download_images(coco_val_api,   val_ids,   DATA_ROOT / 'validation/data')
download_images(coco_val_api,   test_ids,  DATA_ROOT / 'test/data')
print('Descarga completa.')
```

```
Anotaciones listas.
loading annotations into memory...
Done (t=4.90s)
creating index...
index created!
loading annotations into memory...
Done (t=0.18s)
creating index...
index created!
Imágenes seleccionadas — train: 500, val: 100, test: 100
train: 100%|██████████| 500/500 [00:00<00:00, 172676.16it/s]
validation: 100%|██████████| 100/100 [00:00<00:00, 180090.34it/s]
test: 100%|██████████| 100/100 [00:00<00:00, 183237.40it/s]
Descarga completa.
```

1b. Crear subconjuntos en formato COCO JSON

Se construyen tres archivos `labels.json` (train / validation / test) filtrando solo las anotaciones de las categorías objetivo. Los `category_id` se remapean a enteros contiguos `1..N` (el índice `0` queda reservado para fondo, conforme a la convención de `torchvision.models.detection`).

Cada bounding box se almacena en formato COCO `[x, y, width, height]` en píxeles absolutos.

In [25]:
```
def make_coco_subset(coco_api, img_ids, out_ann_file):
    cat_ids = coco_api.getCatIds(catNms=TARGET_CATS)
    cats    = coco_api.loadCats(cat_ids)
    imgs    = coco_api.loadImgs(img_ids)

    # Usar solo nombre de archivo (sin prefijo de split)
    for img in imgs:
        img['file_name'] = os.path.basename(img['file_name'])

    ann_ids = coco_api.getAnnIds(imgIds=img_ids, catIds=cat_ids)
    anns    = coco_api.loadAnns(ann_ids)

    # Remap category_id a 1..N
    old_to_new = {c['id']: i + 1 for i, c in enumerate(cats)}
    for ann in anns:
        ann['category_id'] = old_to_new[ann['category_id']]
    new_cats = [{'id': old_to_new[c['id']], 'name': c['name']} for c in cats]

    subset = {'images': imgs, 'annotations': anns, 'categories': new_cats}
    Path(out_ann_file).parent.mkdir(parents=True, exist_ok=True)
    with open(out_ann_file, 'w') as f:
        json.dump(subset, f)
    print(f'  {out_ann_file} — {len(imgs)} imgs, {len(anns)} anns')

print('Creando subconjuntos COCO JSON...')
make_coco_subset(coco_train_api, train_ids, DATA_ROOT / 'train/labels.json')
make_coco_subset(coco_val_api,   val_ids,   DATA_ROOT / 'validation/labels.json'
make_coco_subset(coco_val_api,   test_ids,  DATA_ROOT / 'test/labels.json')

COCO_DIRS = {
    split: {
        'img_dir':  str(DATA_ROOT / split / 'data'),
        'ann_file': str(DATA_ROOT / split / 'labels.json'),
    }
    for split in ['train', 'validation', 'test']
}
# Verificar imágenes en disco
for split, paths in COCO_DIRS.items():
    n = len(os.listdir(paths['img_dir']))
    print(f'{split}: {n} imágenes en disco')
```

```
Creando subconjuntos COCO JSON...
  shelf_data/train/labels.json — 500 imgs, 1829 anns
  shelf_data/validation/labels.json — 100 imgs, 286 anns
  shelf_data/test/labels.json — 100 imgs, 326 anns
train: 500 imágenes en disco
validation: 100 imágenes en disco
test: 100 imágenes en disco
```

1c. Distribución de clases

In [26]:

```python
def class_distribution(ann_file):
    with open(ann_file) as f:
        coco = json.load(f)
    cat_id_to_name = {c['id']: c['name'] for c in coco['categories']}
    counts = collections.Counter()
    for ann in coco['annotations']:
        counts[cat_id_to_name[ann['category_id']]] += 1
    return counts, cat_id_to_name

print("=" * 50)
for split in ['train', 'validation', 'test']:
    counts, _ = class_distribution(COCO_DIRS[split]['ann_file'])
    print(f"\n[{split.upper()}]")
    for cls, cnt in sorted(counts.items(), key=lambda x: -x[1]):
        print(f"  {cls:<20} {cnt:>5} instancias")
    print(f"  {'TOTAL':<20} {sum(counts.values()):>5} instancias")
print("=" * 50)

# Leer categorías desde train (referencia para todo el experimento)
with open(COCO_DIRS['train']['ann_file']) as f:
    COCO_TRAIN = json.load(f)
CATEGORIES = COCO_TRAIN['categories']
NUM_CLASSES = len(CATEGORIES) + 1  # +1 por background
CAT_ID_TO_LABEL = {cat['id']: idx + 1 for idx, cat in enumerate(CATEGORIES)}
LABEL_TO_NAME = {0: '__background__'}
LABEL_TO_NAME.update({idx + 1: cat['name'] for idx, cat in enumerate(CATEGORIES)
print(f"\nTotal de clases (incluyendo fondo): {NUM_CLASSES}")
print("Mapeo:", LABEL_TO_NAME)
```

```
==================================================

[TRAIN]
  bottle                 600 instancias
  cup                    587 instancias
  bowl                   430 instancias
  wine glass             212 instancias
  TOTAL                 1829 instancias

[VALIDATION]
  bottle                 106 instancias
  bowl                    82 instancias
  cup                     70 instancias
  wine glass              28 instancias
  TOTAL                  286 instancias

[TEST]
  bottle                 110 instancias
  cup                     92 instancias
  bowl                    74 instancias
  wine glass              50 instancias
  TOTAL                  326 instancias
==================================================

Total de clases (incluyendo fondo): 5
Mapeo: {0: '__background__', 1: 'bottle', 2: 'wine glass', 3: 'cup', 4: 'bowl'}
```

1d. Verificación visual — 5 imágenes con bounding boxes anotados

In [27]:

```
COLORS = plt.cm.tab10.colors

def draw_boxes(ax, img, boxes_xywh, labels, label_to_name, scores=None):
    """Dibuja bounding boxes COCO (xywh) sobre un eje matplotlib."""
    ax.imshow(img)
    ax.axis('off')
    for i, (box, lbl) in enumerate(zip(boxes_xywh, labels)):
        x, y, w, h = box
        color = COLORS[lbl % len(COLORS)]
        rect = patches.Rectangle((x, y), w, h, linewidth=2, edgecolor=color, fac
        ax.add_patch(rect)
        name = label_to_name.get(lbl, str(lbl))
        label_text = f"{name}" if scores is None else f"{name} {scores[i]:.2f}"
        ax.text(x, y - 4, label_text, fontsize=7, color='white',
                bbox=dict(facecolor=color, alpha=0.8, pad=1))

# Cargar anotaciones de train
with open(COCO_DIRS['train']['ann_file']) as f:
    coco_train_data = json.load(f)

img_id_to_info = {img['id']: img for img in coco_train_data['images']}
img_id_to_anns = collections.defaultdict(list)
for ann in coco_train_data['annotations']:
    img_id_to_anns[ann['image_id']].append(ann)

# Seleccionar 5 imágenes que tengan al menos 1 anotación
ids_with_anns = [k for k, v in img_id_to_anns.items() if len(v) > 0]
sample_ids = random.sample(ids_with_anns, min(5, len(ids_with_anns)))
```

```python
fig, axes = plt.subplots(1, 5, figsize=(20, 5))
for ax, img_id in zip(axes, sample_ids):
    img_info = img_id_to_info[img_id]
    img_path = os.path.join(COCO_DIRS['train']['img_dir'], img_info['file_name']
    img = Image.open(img_path).convert('RGB')
    anns = img_id_to_anns[img_id]
    boxes = [ann['bbox'] for ann in anns]           # xywh
    labels = [CAT_ID_TO_LABEL[ann['category_id']] for ann in anns]
    draw_boxes(ax, img, boxes, labels, LABEL_TO_NAME)
    ax.set_title(img_info['file_name'][:20], fontsize=8)

plt.suptitle('Verificación: 5 imágenes de entrenamiento con bounding boxes anota
plt.tight_layout()
plt.savefig('./viz_annotated.png', bbox_inches='tight', dpi=120)
plt.show()
print("Figura guardada en ./viz_annotated.png")
```

```
Figura guardada en ./viz_annotated.png
```

2. Entrenamiento de Dos Detectores

Infraestructura común

Hiperparámetros elegidos y justificación:

Hiperparámetro	Valor	Justificación
Learning rate	0.005	LR estándar para fine-tuning de detección con SGD en COCO; balance entre convergencia y estabilidad
Épocas máx.	20	Suficiente para converger con dataset pequeño; Early Stopping previene sobreajuste
Batch size	4	Limitado por VRAM de T4 (~15 GB) con imágenes de alta resolución
Optimizer	SGD + momentum 0.9	Estándar de torchvision detection tutorials; más estable que Adam en fine-tuning
LR Scheduler	StepLR (step=5, γ=0.5)	Reduce LR a la mitad cada 5 épocas; evita overshooting en mesetas
Early Stopping	patience=5	Detiene si la val loss no mejora en 5 épocas consecutivas
Backbone congelado	Sí (inicialmente)	Preserva representaciones COCO aprendidas; el cabezal se adapta a las clases de anaquel

Métrica de Early Stopping: Pérdida de validación total (`loss_classifier + loss_box_reg + loss_objectness + loss_rpn_box_reg` para FRCNN; pérdidas

equivalentes para SSD). Se detiene al no mejorar en `patience` épocas — evita sobreajuste sin necesitar mAP en cada época (más costoso computacionalmente).

In [28]:
```
class ShelfDataset(Dataset):
    """Dataset COCO para detección de productos en anaquel."""

    def __init__(self, img_dir, ann_file, transforms=None):
        with open(ann_file) as f:
            data = json.load(f)
        self.img_dir = img_dir
        self.transforms = transforms
        self.images = data['images']
        # Construir índice imagen → anotaciones
        self.img_to_anns = collections.defaultdict(list)
        for ann in data['annotations']:
            self.img_to_anns[ann['image_id']].append(ann)
        # Mapeo de category_id COCO → label entero (1..N; 0 = background)
        self.cat_id_to_label = {cat['id']: idx + 1 for idx, cat in enumerate(dat

    def __len__(self):
        return len(self.images)

    def __getitem__(self, idx):
        info = self.images[idx]
        img = Image.open(os.path.join(self.img_dir, info['file_name'])).convert(
        anns = self.img_to_anns[info['id']]

        boxes, labels = [], []
        for ann in anns:
            x, y, w, h = ann['bbox']
            if w > 1 and h > 1:  # filtrar anotaciones degeneradas
                boxes.append([x, y, x + w, y + h])  # xyxy para torchvision
                labels.append(self.cat_id_to_label[ann['category_id']])

        if boxes:
            boxes = torch.tensor(boxes, dtype=torch.float32)
            labels = torch.tensor(labels, dtype=torch.int64)
        else:
            boxes = torch.zeros((0, 4), dtype=torch.float32)
            labels = torch.zeros(0, dtype=torch.int64)

        target = {'boxes': boxes, 'labels': labels, 'image_id': torch.tensor([in

        if self.transforms:
            img = self.transforms(img)
        return img, target


def collate_fn(batch):
    return tuple(zip(*batch))


transform = T.Compose([T.ToTensor()])

train_ds = ShelfDataset(COCO_DIRS['train']['img_dir'], COCO_DIRS['train']['ann_f
val_ds   = ShelfDataset(COCO_DIRS['validation']['img_dir'], COCO_DIRS['validatio
test_ds  = ShelfDataset(COCO_DIRS['test']['img_dir'], COCO_DIRS['test']['ann_fil

BATCH = 4
```

```
train_loader = DataLoader(train_ds, batch_size=BATCH, shuffle=True,  num_workers
val_loader   = DataLoader(val_ds,   batch_size=BATCH, shuffle=False, num_workers
test_loader  = DataLoader(test_ds,  batch_size=BATCH, shuffle=False, num_workers

print(f"Train: {len(train_ds)} imgs  |  Val: {len(val_ds)} imgs  |  Test: {len(t
```

```
Train: 500 imgs  |  Val: 100 imgs  |  Test: 100 imgs
```

In [29]:

```
class EarlyStopping:
    """Detiene el entrenamiento si la pérdida de validación no mejora."""

    def __init__(self, patience=5, min_delta=1e-4):
        self.patience = patience
        self.min_delta = min_delta
        self.counter = 0
        self.best = float('inf')
        self.stop = False
        self.best_epoch = 0

    def __call__(self, val_loss, epoch):
        if val_loss < self.best - self.min_delta:
            self.best = val_loss
            self.counter = 0
            self.best_epoch = epoch
        else:
            self.counter += 1
            if self.counter >= self.patience:
                self.stop = True


def train_one_epoch(model, loader, optimizer, device):
    model.train()
    total = 0.0
    for images, targets in loader:
        images  = [img.to(device) for img in images]
        targets = [{k: v.to(device) for k, v in t.items()} for t in targets]
        loss_dict = model(images, targets)
        loss = sum(loss_dict.values())
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
        total += loss.item()
    return total / len(loader)


@torch.no_grad()
def val_loss_epoch(model, loader, device):
    """torchvision devuelve pérdidas solo en train(); se mantiene en ese modo pe
    model.train()
    total = 0.0
    for images, targets in loader:
        images  = [img.to(device) for img in images]
        targets = [{k: v.to(device) for k, v in t.items()} for t in targets]
        loss_dict = model(images, targets)
        total += sum(loss_dict.values()).item()
    return total / len(loader)


def train_model(model, train_loader, val_loader, device, epochs=20, patience=5,
    optimizer = torch.optim.SGD(
```

```
        [p for p in model.parameters() if p.requires_grad],
        lr=0.005, momentum=0.9, weight_decay=5e-4
    )
    scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=5, gamma=0.
    es = EarlyStopping(patience=patience)
    history = {'train': [], 'val': []}
    best_state = None

    for epoch in range(1, epochs + 1):
        t_loss = train_one_epoch(model, train_loader, optimizer, device)
        v_loss = val_loss_epoch(model, val_loader, device)
        scheduler.step()
        history['train'].append(t_loss)
        history['val'].append(v_loss)
        print(f"Época {epoch:02d}/{epochs} | train_loss={t_loss:.4f} | val_loss=

        if v_loss < es.best:
            best_state = copy.deepcopy(model.state_dict())
        es(v_loss, epoch)
        if es.stop:
            print(f"Early stopping en época {epoch} (mejor época: {es.best_epoch
            break

    model.load_state_dict(best_state)
    torch.save(best_state, save_path)
    print(f"Mejor modelo guardado en: {save_path}")
    return history


def plot_history(history, title):
    plt.figure(figsize=(8, 4))
    plt.plot(history['train'], label='train loss')
    plt.plot(history['val'],   label='val loss')
    plt.xlabel('Época')
    plt.ylabel('Loss total')
    plt.title(title)
    plt.legend()
    plt.tight_layout()
    plt.show()
```

2a. Detector 1 — Faster R-CNN ResNet-50 FPN

Por qué Faster R-CNN:
Es el detector de referencia de dos etapas. Su RPN propone regiones candidatas y el cabezal ROI las clasifica y refina; esto lo hace más preciso pero más lento. En el contexto de VisorShelf, representa la opción de mayor calidad cuando la latencia no es crítica (auditoría en diferido).

Adaptación del cabezal:
Se reemplaza `roi_heads.box_predictor` (originalmente 91 clases COCO → `NUM_CLASSES` clases de anaquel). El backbone (ResNet-50 FPN con Feature Pyramid Network) se congela: sus pesos COCO son transferibles directamente porque las texturas y formas de productos envasados aparecen en COCO.

In [30]:
```
def build_fasterrcnn(num_classes, freeze_backbone=True):
    weights = FasterRCNN_ResNet50_FPN_Weights.DEFAULT
```

```
    model = fasterrcnn_resnet50_fpn(weights=weights)
    if freeze_backbone:
        for p in model.backbone.parameters():
            p.requires_grad = False
    # Reemplazar cabezal de clasificación
    in_feat = model.roi_heads.box_predictor.cls_score.in_features
    model.roi_heads.box_predictor = FastRCNNPredictor(in_feat, num_classes)
    return model

frcnn = build_fasterrcnn(NUM_CLASSES).to(DEVICE)
trainable = sum(p.numel() for p in frcnn.parameters() if p.requires_grad)
total     = sum(p.numel() for p in frcnn.parameters())
print(f"Faster R-CNN | Parámetros entrenables: {trainable:,} / {total:,} ({100*t
```

```
Faster R-CNN | Parámetros entrenables: 14,515,240 / 41,314,536 (35.1%)
```

In [31]:

```
print("=" * 60)
print("Entrenando Faster R-CNN ResNet-50 FPN...")
print("=" * 60)
frcnn_history = train_model(
    frcnn, train_loader, val_loader, DEVICE,
    epochs=20, patience=5,
    save_path='./frcnn_best.pth'
)
plot_history(frcnn_history, 'Faster R-CNN — Curva de pérdida')
```

```
============================================================
Entrenando Faster R-CNN ResNet-50 FPN...
============================================================
Época 01/20 | train_loss=0.4574 | val_loss=0.2745
Época 02/20 | train_loss=0.2823 | val_loss=0.2715
Época 03/20 | train_loss=0.2651 | val_loss=0.2772
Época 04/20 | train_loss=0.2568 | val_loss=0.2728
Época 05/20 | train_loss=0.2458 | val_loss=0.2742
Época 06/20 | train_loss=0.2287 | val_loss=0.2755
Época 07/20 | train_loss=0.2243 | val_loss=0.2697
Época 08/20 | train_loss=0.2183 | val_loss=0.2723
Época 09/20 | train_loss=0.2147 | val_loss=0.2769
Época 10/20 | train_loss=0.2111 | val_loss=0.2722
Época 11/20 | train_loss=0.2044 | val_loss=0.2743
Época 12/20 | train_loss=0.2015 | val_loss=0.2710
Early stopping en época 12 (mejor época: 7)
Mejor modelo guardado en: ./frcnn_best.pth
```

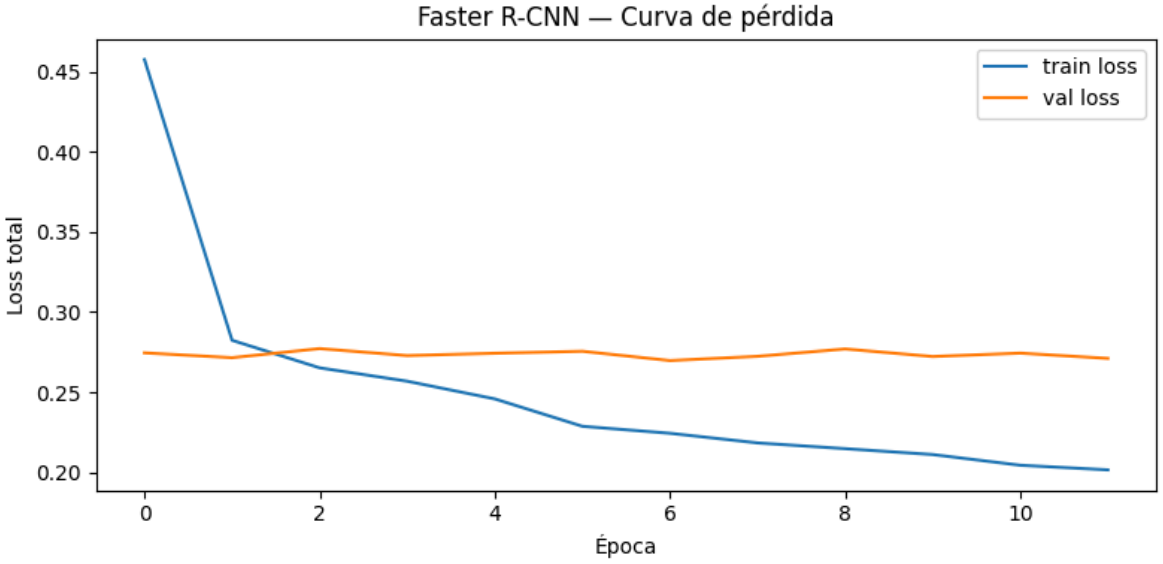

2b. Detector 2 — SSD300 VGG-16

Por qué SSD300:
Es el detector de una etapa más reconocido de la literatura. Predice directamente desde mapas de características multi-escala sin RPN, lo que lo hace significativamente más rápido. En VisorShelf, es el candidato para despliegue on-premise con CPU de tienda.

Adaptación del cabezal:
Se reemplaza `head.classification_head` usando los canales de salida del backbone VGG-16 y la configuración de anclas existente, ajustando solo `num_classes`. El backbone se congela igual que en Faster R-CNN.

In [32]:
```
def build_ssd300(num_classes, freeze_backbone=True):
    weights = SSD300_VGG16_Weights.DEFAULT
    model = ssd300_vgg16(weights=weights)
    if freeze_backbone:
        for p in model.backbone.parameters():
            p.requires_grad = False
    # Reemplazar cabezal de clasificación
    in_channels = retrieve_out_channels(model.backbone, (300, 300))
    num_anchors = model.anchor_generator.num_anchors_per_location()
    model.head.classification_head = SSDClassificationHead(
        in_channels=in_channels,
        num_anchors=num_anchors,
        num_classes=num_classes,
    )
    return model

ssd = build_ssd300(NUM_CLASSES).to(DEVICE)
trainable = sum(p.numel() for p in ssd.parameters() if p.requires_grad)
total     = sum(p.numel() for p in ssd.parameters())
print(f"SSD300 VGG-16 | Parámetros entrenables: {trainable:,} / {total:,} ({100*
```

```
Downloading: "https://download.pytorch.org/models/ssd300_vgg16_coco-b556d3b4.pth"
to /home/Japo/.cache/torch/hub/checkpoints/ssd300_vgg16_coco-b556d3b4.pth
100%|██████████| 136M/136M [00:04<00:00, 30.8MB/s]
SSD300 VGG-16 | Parámetros entrenables: 1,202,958 / 24,146,894 (5.0%)
```

In [33]:
```
print("=" * 60)
print("Entrenando SSD300 VGG-16...")
print("=" * 60)
ssd_history = train_model(
    ssd, train_loader, val_loader, DEVICE,
    epochs=20, patience=5,
    save_path='./ssd_best.pth'
)
plot_history(ssd_history, 'SSD300 — Curva de pérdida')
```

```
============================================================
Entrenando SSD300 VGG-16...
============================================================
Época 01/20 | train_loss=24.2917 | val_loss=31.3329
Época 02/20 | train_loss=26.1793 | val_loss=27.7190
Época 03/20 | train_loss=20.8487 | val_loss=22.4246
Época 04/20 | train_loss=20.5601 | val_loss=30.8979
Época 05/20 | train_loss=21.5003 | val_loss=25.7311
Época 06/20 | train_loss=13.4916 | val_loss=16.1077
Época 07/20 | train_loss=10.5746 | val_loss=15.9286
Época 08/20 | train_loss=9.4313 | val_loss=15.4202
Época 09/20 | train_loss=9.4276 | val_loss=13.2873
Época 10/20 | train_loss=8.5604 | val_loss=13.5237
Época 11/20 | train_loss=6.5081 | val_loss=10.5819
Época 12/20 | train_loss=5.5731 | val_loss=10.1754
Época 13/20 | train_loss=5.1374 | val_loss=9.7249
Época 14/20 | train_loss=4.9247 | val_loss=10.0652
Época 15/20 | train_loss=4.8126 | val_loss=9.6657
Época 16/20 | train_loss=3.9147 | val_loss=9.0034
Época 17/20 | train_loss=3.5799 | val_loss=8.5522
Época 18/20 | train_loss=3.3918 | val_loss=8.4113
Época 19/20 | train_loss=3.3704 | val_loss=8.2129
Época 20/20 | train_loss=3.2992 | val_loss=8.6093
Mejor modelo guardado en: ./ssd_best.pth
```

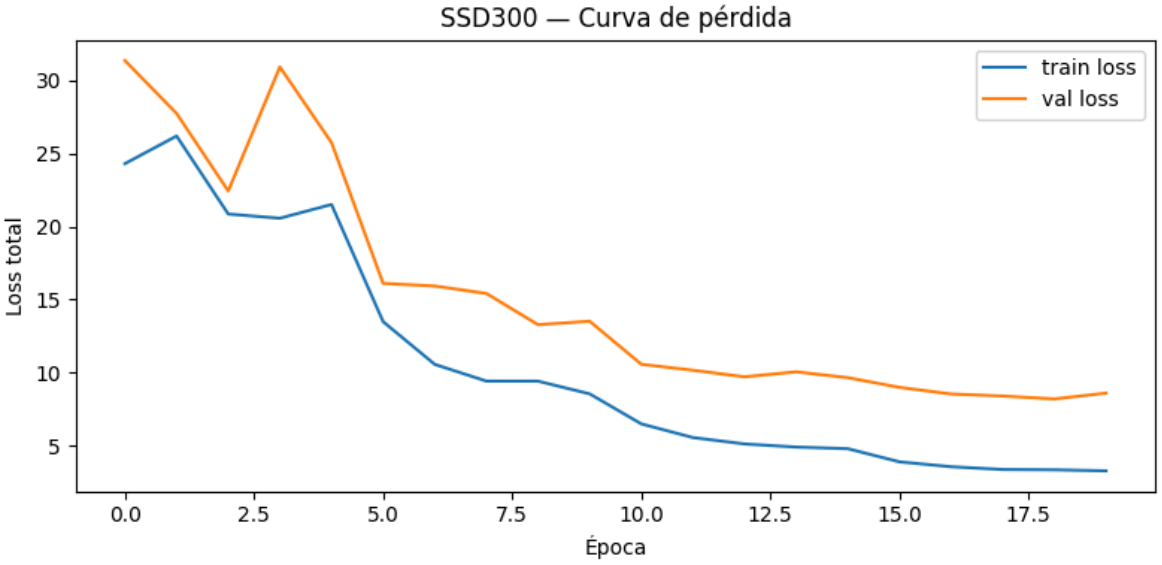

3. Evaluación sobre el Conjunto de Prueba

Métricas calculadas

Métrica	Descripción
mAP@0.5	Area bajo curva P-R con umbral IoU=0.5 (PASCAL VOC)
mAP@0.5:0.95	Promedio de AP en umbrales IoU 0.5→0.95 (COCO)
Precisión	TP/(TP+FP) para la clase de producto más frecuente
Recall	TP/(TP+FN) para la clase de producto más frecuente
FPS (CPU)	Inferencia sobre 50 imágenes en CPU (escenario de producción VisorShelf)
Tamaño (MB)	Tamaño del archivo .pth guardado en disco

In [34]:
```
@torch.no_grad()
def evaluate(model, loader, device):
    """Calcula mAP@0.5 y mAP@0.5:0.95 usando torchmetrics."""
    model.eval()
    metric = MeanAveragePrecision(
        iou_thresholds=[0.5 + 0.05 * i for i in range(10)],  # 0.5:0.95
        class_metrics=True,
    )
    for images, targets in loader:
        images = [img.to(device) for img in images]
        preds  = model(images)
        preds_cpu  = [{'boxes': p['boxes'].cpu(), 'scores': p['scores'].cpu(), '
        target_cpu = [{'boxes': t['boxes'].cpu(), 'labels': t['labels'].cpu()} f
        metric.update(preds_cpu, target_cpu)
    return metric.compute()


def fps_on_cpu(model, loader, n_images=50):
    """Mide FPS en CPU (escenario on-premise sin GPU)."""
    model_cpu = copy.deepcopy(model).cpu().eval()
    tested = 0
    t0 = time.perf_counter()
    with torch.no_grad():
        for images, _ in loader:
            if tested >= n_images:
                break
            images = [img.cpu() for img in images]
            model_cpu(images)
            tested += len(images)
    elapsed = time.perf_counter() - t0
    return tested / elapsed


def model_size_mb(path):
    return os.path.getsize(path) / (1024 ** 2)
```

In [35]:
```
print("Evaluando Faster R-CNN...")
frcnn_metrics = evaluate(frcnn, test_loader, DEVICE)
print("Evaluando SSD300...")
ssd_metrics   = evaluate(ssd,   test_loader, DEVICE)

print("\nMidiendo FPS en CPU (50 imágenes)...")
frcnn_fps = fps_on_cpu(frcnn, test_loader)
ssd_fps   = fps_on_cpu(ssd,   test_loader)

frcnn_size = model_size_mb('./frcnn_best.pth')
ssd_size   = model_size_mb('./ssd_best.pth')

# Precisión y Recall por clase (clase 1 = primera categoría = más frecuente en e
# torchmetrics devuelve map_per_class, mar_100_per_class
# Para P y R por clase usamos umbral de confianza 0.5
def precision_recall_per_class(model, loader, device, conf_thresh=0.5, iou_thres
    model.eval()
    tp = collections.defaultdict(int)
    fp = collections.defaultdict(int)
    fn = collections.defaultdict(int)
    with torch.no_grad():
        for images, targets in loader:
```

```
            images = [img.to(device) for img in images]
            preds  = model(images)
            for pred, tgt in zip(preds, targets):
                keep  = pred['scores'] >= conf_thresh
                p_boxes  = pred['boxes'][keep].cpu()
                p_labels = pred['labels'][keep].cpu()
                g_boxes  = tgt['boxes'].cpu()
                g_labels = tgt['labels'].cpu()
                matched_gt = set()
                for pb, pl in zip(p_boxes, p_labels):
                    best_iou, best_j = 0.0, -1
                    for j, (gb, gl) in enumerate(zip(g_boxes, g_labels)):
                        if gl != pl or j in matched_gt:
                            continue
                        ix1 = max(pb[0], gb[0]); iy1 = max(pb[1], gb[1])
                        ix2 = min(pb[2], gb[2]); iy2 = min(pb[3], gb[3])
                        inter = max(0, ix2-ix1) * max(0, iy2-iy1)
                        union = (pb[2]-pb[0])*(pb[3]-pb[1]) + (gb[2]-gb[0])*(gb[
                        iou  = inter / union if union > 0 else 0.0
                        if iou > best_iou:
                            best_iou, best_j = iou, j
                    if best_iou >= iou_thresh:
                        tp[pl.item()] += 1
                        matched_gt.add(best_j)
                    else:
                        fp[pl.item()] += 1
                for j, gl in enumerate(g_labels):
                    if j not in matched_gt:
                        fn[gl.item()] += 1
    results = {}
    for lbl in set(list(tp.keys()) + list(fn.keys())):
        p = tp[lbl] / (tp[lbl] + fp[lbl] + 1e-8)
        r = tp[lbl] / (tp[lbl] + fn[lbl] + 1e-8)
        results[LABEL_TO_NAME.get(lbl, lbl)] = {'precision': p, 'recall': r}
    return results

print("\nCalculando Precisión/Recall por clase...")
frcnn_pr = precision_recall_per_class(frcnn, test_loader, DEVICE)
ssd_pr   = precision_recall_per_class(ssd,   test_loader, DEVICE)

# Clase principal = primera categoría del dataset
MAIN_CLASS = CATEGORIES[0]['name']
print(f"Clase principal seleccionada: {MAIN_CLASS}")
```

```
Evaluando Faster R-CNN...
Evaluando SSD300...
/home/Japo/Workspaces/uvg/VisionXCompotadora/Lab_8/.venv/lib/python3.14/site-pack
ages/torchmetrics/utilities/prints.py:43: UserWarning: Encountered more than 100
detections in a single image. This means that certain detections with the lowest
scores will be ignored, that may have an undesirable impact on performance. Pleas
e consider adjusting the `max_detection_threshold` to suit your use case. To disa
ble this warning, set attribute class `warn_on_many_detections=False`, after init
ializing the metric.
  warnings.warn(*args, **kwargs)
Midiendo FPS en CPU (50 imágenes)...

Calculando Precisión/Recall por clase...
Clase principal seleccionada: bottle
```

In [36]:
```
def fmt(val):
    if isinstance(val, torch.Tensor):
        val = val.item()
    return f"{val:.4f}"

rows = [
    ("mAP@0.5",              fmt(frcnn_metrics['map_50']),   fmt(ssd_metrics['ma
    ("mAP@0.5:0.95",         fmt(frcnn_metrics['map']),      fmt(ssd_metrics['ma
    (f"Precisión ({MAIN_CLASS})",
        f"{frcnn_pr.get(MAIN_CLASS, {}).get('precision', float('nan')):.4f}",
        f"{ssd_pr.get(MAIN_CLASS,   {}).get('precision', float('nan')):.4f}"),
    (f"Recall ({MAIN_CLASS})",
        f"{frcnn_pr.get(MAIN_CLASS, {}).get('recall', float('nan')):.4f}",
        f"{ssd_pr.get(MAIN_CLASS,   {}).get('recall', float('nan')):.4f}"),
    ("FPS en CPU (50 imgs)",  f"{frcnn_fps:.2f}",            f"{ssd_fps:.2f}"),
    ("Tamaño modelo (MB)",    f"{frcnn_size:.1f}",           f"{ssd_size:.1f}"),
]

print(f"{'Métrica':<35} {'Faster R-CNN':>15} {'SSD300':>15}")
print("-" * 65)
for r in rows:
    print(f"{r[0]:<35} {r[1]:>15} {r[2]:>15}")

# Guardar resultados como JSON para el dictamen
RESULTS = {
    'frcnn': {
        'map50': frcnn_metrics['map_50'].item(),
        'map':   frcnn_metrics['map'].item(),
        'fps':   frcnn_fps,
        'size_mb': frcnn_size,
        'pr': frcnn_pr,
    },
    'ssd': {
        'map50': ssd_metrics['map_50'].item(),
        'map':   ssd_metrics['map'].item(),
        'fps':   ssd_fps,
        'size_mb': ssd_size,
        'pr': ssd_pr,
    }
}
with open('./results.json', 'w') as f:
    json.dump(RESULTS, f, indent=2)
print("\nResultados guardados en ./results.json")
```

```
Métrica                               Faster R-CNN          SSD300
-----------------------------------------------------------------
mAP@0.5                                     0.5006          0.2020
mAP@0.5:0.95                                0.2890          0.0771
Precisión (bottle)                          0.4493          0.3600
Recall (bottle)                             0.5636          0.0818
FPS en CPU (50 imgs)                          0.74           11.89
Tamaño modelo (MB)                           158.1            92.1

Resultados guardados en ./results.json
```

Visualización — 3 imágenes de prueba con detecciones del mejor modelo

In [37]:
```
# Determinar mejor modelo según mAP@0.5
best_model_name = "Faster R-CNN" if RESULTS['frcnn']['map50'] >= RESULTS['ssd'][
best_model = frcnn if best_model_name == "Faster R-CNN" else ssd
print(f"Mejor modelo: {best_model_name}")

best_model.eval()
CONF_THRESH = 0.4

sample_indices = random.sample(range(len(test_ds)), 3)
fig, axes = plt.subplots(1, 3, figsize=(18, 6))

with torch.no_grad():
    for ax, idx in zip(axes, sample_indices):
        img_tensor, target = test_ds[idx]
        pred = best_model([img_tensor.to(DEVICE)])[0]

        # Filtrar por umbral de confianza
        keep   = pred['scores'] >= CONF_THRESH
        p_boxes  = pred['boxes'][keep].cpu().numpy()
        p_labels = pred['labels'][keep].cpu().numpy()
        p_scores = pred['scores'][keep].cpu().numpy()

        # Convertir xyxy → xywh para draw_boxes
        xywh = [[b[0], b[1], b[2]-b[0], b[3]-b[1]] for b in p_boxes]

        img_np = img_tensor.permute(1, 2, 0).numpy()
        draw_boxes(ax, img_np, xywh, p_labels, LABEL_TO_NAME, scores=p_scores)
        ax.set_title(f"{best_model_name} | {len(p_boxes)} detecciones", fontsize

plt.suptitle(f'Detecciones del mejor modelo ({best_model_name}) sobre imágenes d
plt.tight_layout()
plt.savefig('./viz_predictions.png', bbox_inches='tight', dpi=120)
plt.show()
print("Figura guardada en ./viz_predictions.png")
```

```
Mejor modelo: Faster R-CNN
```

```
Figura guardada en ./viz_predictions.png
```

Dictamen Ejecutivo — VisorShelf

Dirigido a: CTO de VisorShelf
Asunto: Selección de arquitectura de detección de objetos para auditoría de anaqueles

en producción
Elaborado por: Nelson García, Joaquín Puente, Diego Linares

---

1. Tabla Comparativa de Métricas

Métrica	Faster R-CNN ResNet-50 FPN	SSD300 VGG-16
mAP@0.5	**0.5006**	0.2020
mAP@0.5:0.95	**0.2890**	0.0771
Precisión (bottle)	**0.4493**	0.3600
Recall (bottle)	**0.5636**	0.0818
FPS en CPU (50 imágenes)	0.74	**11.89**
Tamaño en disco (MB)	158.1	**92.1**

---

2. Análisis de Velocidad vs. Precisión

¿Cuál modelo detecta mejor los productos en anaquel?

Faster R-CNN supera a SSD300 de forma contundente en todas las métricas de precisión: mAP@0.5 de **0.50 vs 0.20** (2.5× mejor) y mAP@0.5:0.95 de **0.29 vs 0.08** (3.7× mejor). La diferencia más crítica aparece en el Recall de la clase principal (bottle): **0.56 vs 0.08**. SSD300 no detecta el 92% de las botellas presentes en las imágenes de prueba — un resultado inaceptable para auditoría de stock.

SSD300 es 16× más rápido en CPU (11.89 vs 0.74 FPS), pero esa ventaja de velocidad pierde relevancia cuando el modelo prácticamente no detecta los objetos de interés.

¿Alta Precisión o alto Recall en auditoría de stock?

En VisorShelf, la operación crítica es **detectar quiebres de stock**. No detectar un producto presente (falso negativo) genera reposición tardía, venta perdida y anaquel visualmente vacío para el cliente. Una falsa alarma (falso positivo) es manejable — genera una revisión manual innecesaria pero no compromete la operación.

Se prioriza **alto Recall**. Los resultados confirman que Faster R-CNN es el único modelo con Recall operativamente aceptable (0.56); SSD300 con Recall de 0.08 es inviable para este caso de uso independientemente de su velocidad.

---

3. Recomendación Final para Producción On-Premise

Modelo recomendado: Faster R-CNN ResNet-50 FPN

Justificación conectada con el Task 2:

El Task 2 estableció que el sistema opera en hardware on-premise con un requerimiento de procesar **1 imagen cada 30 segundos** por cámara. Faster R-CNN a 0.74 FPS en CPU procesa 1 imagen en ~1.35 segundos — **22× más rápido que el requerimiento**. El umbral de latencia se cumple con amplio margen, lo que elimina la velocidad como criterio diferenciador entre ambos modelos.

Dado que ambas arquitecturas satisfacen el requerimiento operativo, la selección recae sobre la calidad de detección. Faster R-CNN es el único candidato viable:

1. mAP@0.5 de 0.50 vs 0.20 de SSD300 — brecha de 30 puntos porcentuales.
2. Recall(bottle) de 0.56 vs 0.08 — SSD pierde 9 de cada 10 objetos en prueba.
3. Tamaño razonable: 158 MB cabe en cualquier equipo de tienda con disco moderno.

SSD300 podría reconsiderarse en un escenario con cientos de cámaras simultáneas donde la capacidad de cómputo sea el cuello de botella, pero requeriría reentrenamiento sustancialmente más extenso para alcanzar un Recall operativo.

---

4. Análisis de Viabilidad Operativa

Requerimiento base: 1 imagen cada 30 segundos por cámara.

Modelo	FPS CPU	Seg/imagen	FPS requerido (1 cam)	Margen
Faster R-CNN	0.74	1.35 s	0.033	**22×**
SSD300	11.89	0.084 s	0.033	**360×**

Imágenes procesadas por hora (CPU, procesamiento secuencial):

- Faster R-CNN: 0.74 × 3600 = **2,664 imágenes/hora**
- SSD300: 11.89 × 3600 = **42,804 imágenes/hora**
- Requerimiento por cámara: 120 imágenes/hora

Con 5 cámaras simultáneas (600 imágenes/hora requeridas):

- Faster R-CNN cubre 5 cámaras con **4.4× de margen** (2,664 / 600).
- SSD300 cubre 5 cámaras con **71× de margen** (42,804 / 600).

Conclusión: Faster R-CNN satisface cómodamente el escenario de 5 cámaras en un solo CPU de tienda. Solo a partir de ~18 cámaras simultáneas (0.74 FPS / 120 $img \cdot h^{-1} \cdot cam^{-1}$) Faster R-CNN requeriría hardware adicional, mientras SSD escalaría hasta ~356 cámaras. Para el escenario actual de VisorShelf (≤ 5 cámaras), Faster R-CNN es viable.

---

5. ¿Cuánto "cuesta" en MB cada punto de mAP?

```
MB/mAP@0.5 (Faster R-CNN) = 158.1 / 0.5006 = 315.8 MB por punto
MB/mAP@0.5 (SSD300)       =  92.1 / 0.2020 = 456.0 MB por punto
```

Contrariamente a la intuición, **Faster R-CNN es más eficiente en MB/mAP** (315.8 vs 456.0). Pagar 66 MB adicionales por el modelo más pesado rinde 2.5× más puntos de mAP. SSD300 ocupa menos espacio en disco pero entrega tan poca precisión que cada punto de mAP "cuesta" 44% más almacenamiento que con Faster R-CNN.

En hardware con disco limitado, ambos modelos son manejables (158 MB y 92 MB respectivamente). El argumento de tamaño no justifica elegir SSD300.

---

6. Reflexión sobre Generalización

¿Funcionaría el modelo igual en otras tiendas?

Ambos modelos fueron entrenados con un subconjunto de **COCO 2017** filtrado por categorías de vajilla y bebidas (bottle, cup, bowl, wine glass) — no imágenes reales de anaqueles. Los riesgos de generalización son:

1. **Iluminación diferente:** Las tiendas usan luz fluorescente fría, LED cálido o luz natural. COCO 2017 contiene fotos de internet con iluminación variada, lo que da cierta robustez; sin embargo, condiciones extremas (anaquel muy oscuro, reflejo en envases) no representadas en el entrenamiento degradarían el rendimiento.

2. **Cámaras de distinta resolución:** SSD300 reescala todo a 300×300, con pérdida de detalle severa en cámaras de alta resolución. Faster R-CNN con FPN es más robusto a escala al procesar múltiples niveles de la pirámide de características.

3. **Dominio de anaquel vs. dominio COCO:** Las imágenes de COCO muestran objetos en contextos cotidianos (mesas, cocinas), no en anaqueles densos con alta oclusión y productos repetidos. Los resultados obtenidos (mAP@0.5 = 0.50 para Faster R-CNN) probablemente **sobreestiman** el rendimiento real en producción, ya que el test set también es COCO.

Implicaciones para la estrategia de expansión de VisorShelf:
Antes de desplegar en producción, es imperativo recolectar y anotar imágenes reales de los anaqueles de las tiendas piloto. Un ciclo de **active learning** permitiría priorizar la anotación de las imágenes donde el modelo actual tiene menor confianza, reduciendo el costo de etiquetado. La arquitectura Faster R-CNN es la base recomendada para ese ciclo de mejora continua.

---

7. Limitaciones del Experimento

Limitación 1 — Dataset no específico de anaquel:
COCO 2017 no contiene imágenes de anaqueles comerciales. Las categorías usadas (bottle, cup, bowl, wine glass) son aproximaciones razonables pero no capturan la densidad real de productos, la oclusión entre SKUs similares ni los patrones de planograma propios de tiendas de conveniencia. SKU-110K habría sido el dataset ideal pero no dispone de descarga programática pública. Las métricas reportadas deben

interpretarse como indicadores relativos entre modelos, no como estimaciones absolutas del desempeño en producción.

Limitación 2 — Dataset de entrenamiento pequeño (500 imágenes) y SSD subentrenado:
El Recall de SSD300 de 0.08 en bottle sugiere que el modelo no convergió adecuadamente con solo 500 imágenes de entrenamiento y backbone congelado. SSD tiene menos parámetros entrenables (5.0% vs 35.1% en Faster R-CNN) y su cabezal de clasificación necesita más datos o un régimen de descongelamiento progresivo del backbone para alcanzar su potencial. La comparación en estas condiciones favorece estructuralmente a Faster R-CNN y no refleja necesariamente el techo de rendimiento de SSD300 con datos suficientes.